计算机科学 COMPUTER SCIENCE
http://www.jsjkx.com
DOI:10.11896/jsjkx.250700092

融合多视角习题表征与遗忘机制的深度知识追踪

于程程　姜永发　陈方疏　王家辉　孟宪凯
上海第二工业大学计算机与信息工程学院　上海 201209
(ccyu@sspu.edu.cn)

摘　要　知识追踪是智能教育系统中的核心任务,即根据学习者历史答题行为对知识点掌握程度进行建模并预测下一个答题结果。然而,现有方法普遍存在3个局限:1)多数依赖习题编号或知识点标签,未充分挖掘习题和知识点之间复杂的图结构特征以提高习题表征能力;2)未充分利用习题多维度属性信息来进一步提升习题嵌入表达能力;3)未充分考虑学习者学习知识遗忘规律对知识掌握的影响,导致预测效果受限。因此,提出一种融合多视角习题表征与遗忘机制的深度知识追踪模型(MEFKT),利用预训练模型学习具有高质量表达能力的习题嵌入,并结合学习者学习规律对答题行为进行预测。首先,基于习题关系图,利用无监督对比学习方法预训练包含图结构信息的习题表征;同时,基于习题/知识点相似性、习题难度、习题类型和习题答题时长等信息,构建包含多维度属性的预训练习题表征;接着,利用线性融合对齐机制,将多视角习题表征映射到同一表征空间,得到最终的习题表征;最后,结合遗忘机制构建行为预测模型,实现对学习者知识状态的动态更新及对下一个答题结果的预测。在两个公开数据集上进行的实验表明,MEFKT在预测效果上显著优于基准模型,其具备有效性和先进性。

关键词:知识追踪;习题表征;图对比学习;遗忘机制
中图分类号　TP391

Multi-view Exercise Representation and Forgetting Mechanism for Deep Knowledge Tracing

YU Chengcheng, JIANG Yongfa, CHEN Fangshu, WANG Jiahui and MENG Xiankai
School of Computer and Information Engineering, Shanghai Polytechnic University, Shanghai 201209, China

Abstract　Knowledge tracing is a core task in intelligent tutoring systems, which aims to model a learner's mastery of knowledges based on their historical interaction behaviors and predict the next exercise answer. However, existing approaches suffer from three main limitations: 1) Most methods rely heavily on exercise or knowledge IDs, lacking the ability to capture complex structural dependencies between exercises and knowledge concepts to enhance exercise representation; 2) They fail to effectively utilize multi-dimensional exercise attributes to enrich exercise embeddings; 3) They overlook the impact of forgetting patterns in learners' cognitive processes, which limits predictive performance. To address these issues, Multi-view Exercise representation and Forgetting mechanism for deep Knowledge Tracing (MEFKT) is proposed. Specifically, MEFKT leverages pre-trained models to learn high-quality exercise embeddings and predicts learner responses based on learning dynamics. Firstly, a graph-based contrastive learning strategy is adopted to pre-train exercise representations enriched with structural information. At the same time, it constructs attribute-enhanced pre-trained embeddings that capture multi-dimensional features such as exercise/knowledge similarity, exercise difficulty, exercise type, and response time. These multiple perspectives are then fused into a unified representation space via a learnable linear alignment module. Finally, a behavior prediction module incorporating a forgetting mechanism is designed to dynamically update knowledge states and predict the next response. Extensive experiments on two public benchmark datasets demonstrate that MEFKT significantly outperforms existing state-of-the-art knowledge tracing models, validating the effectiveness of integrating multi-view exercise representations and forgetting-aware learning dynamics.

Keywords　Knowledge tracing, Exercise representation, Graph contrastive learning, Forgetting mechanism

1　引言

在智能教育与自适应学习系统快速发展的背景下,如何有效追踪学习者对知识的掌握情况是教育人工智能领域的重要研究课题。知识追踪(Knowledge Tracing, KT)作为评估学习者动态认知状态的重要技术,能够通过分析学习者的历史答题行为,预测其对后续习题的回答情况,从而为个性化能力培养提供支持[1-3]。

到稿日期:2025-07-15　返修日期:2025-10-19
基金项目:上海市自然科学基金(24ZR1425500,25ZR1402173)
This work was supported by the Natural Science Foundation of Shanghai, China (24ZR1425500, 25ZR1402173).
通信作者:陈方疏(fschen@sspu.edu.cn)

中国知网　https://www.cnki.net

早期的知识追踪模型[4-5]往往假设学习者知识状态为静态且知识点独立，难以贴合真实学习过程。近年来，深度知识追踪模型得到广泛研究[6-7]。DKT[8]首次利用循环神经网络处理学习者的答题序列，捕获了学习过程的动态特征。然而，DKT 缺少捕捉序列数据中长期依赖的能力。对此，SAKT[9]和 AKT[10]引入注意力机制来进一步提升模型的性能。一些方法通过引入辅助信息来提升模型预测性能，如 LBKT[11]引入行为特征学习知识状态的变化。还有一些方法通过增强习题特征来提高知识追踪预测性能，如 PEBG[12]利用预训练模型学习具有更强表达能力的习题表征，Bi-CLKT[13]基于习题和知识点关系图，结合对比学习获得习题表征。

然而，现有方法普遍存在以下局限。首先，图结构信息缺失导致习题嵌入表达能力不足，现有方法多数依赖习题编号，忽略或未能充分挖掘习题和知识点之间的复杂关联结构信息。其次，图结构信息与属性信息难以融合并协同影响习题表征质量，习题相关属性信息(包括习题难度、答题时长、习题类型、习题相似性等)对于构建习题表征也有重要意义。例如，不同习题具有同一单一知识点，由于难度不同，预测结果可能不同。最后，未能充分考虑学习者学习知识规律对知识掌握预测的影响，导致预测效果受限。例如，学习者在学习过程中存在遗忘规律，对知识的掌握程度随时间而下降。

为应对以上挑战，提出了一种融合多视角习题表征与遗忘机制的深度知识追踪模型(MEFKT)。该模型利用预训练模型学习具有高质量表达能力的习题嵌入，并结合学习者的学习规律对答题行为进行预测。首先，基于习题关系图，利用无监督对比学习方法学习包含图结构信息的习题表征；同时，基于习题/知识点相似性、习题难度等信息，构建基于多维度属性的习题表征；接着，利用线性映射融合机制，将多视角信息统一至同一表征空间，得到最终的习题表征；最后，受艾宾浩斯遗忘曲线的启发，利用融合指数衰减的注意力机制进行行为预测建模，实现对学习者知识状态的动态更新及对下一个答题结果的预测。本文的主要贡献如下：

1)提出了一种多视角融合的习题表征学习方法。基于习题关系图，结合无监督图对比学习方法，获得全局结构感知的习题表征，同时，结合多维度辅助信息获得具有多维度属性信息感知的习题表征，并将两类嵌入映射至统一空间，进而从多个视角提高习题表征的表达能力。

2)设计了一种融合遗忘机制的行为预测模型。利用一个指数衰减的注意力机制将学习者遗忘规律融入行为预测模型中，同时捕捉答题序列中的长期依赖信息，结合多视角增强的习题表征，实现融合遗忘机制的学习者知识状态动态建模。

3)在两个公开数据集上进行了对比实验和消融实验，并可视化了 MEFKT 模型的知识追踪效果。MEFKT 模型在预测效果上显著优于基准模型，其具备有效性和先进性。

2 相关工作

2.1 知识追踪

知识追踪旨在通过分析学习者的学习行为数据，对学习者的知识点掌握情况进行建模。早期的知识追踪模型主要基于统计学方法，如 BKT 模型[4]和 IRT 模型[5]。尽管这些模型有一定的预测效果，但它们往往假设学习者的知识状态为静态且知识点独立，难以贴合真实的学习过程。

随着深度学习技术的发展，深度知识追踪模型被广泛研究[6-7]。DKT[8]首次引入循环神经网络对学习者答题序列建模，有效捕获了学习过程的动态特征，但其难以捕获序列数据的长期依赖关系，且忽略了很多影响因素，如遗忘因素，数据稀疏问题，辅助信息(习题难度、答题时间等特征)。对此，SAKT[9]通过引入自注意力机制提升了对答题行为的全局建模能力。AKT[10]进一步引入指数衰减的注意力机制，并结合 IRT 提升预测性能。DKVMN[14]使用动态键值存储网络分别存储和更新习题与学习者知识水平信息。有些方法利用习题-知识点关系图学习具有更好表达能力的习题表征，以解决行为数据稀疏导致的学习者知识掌握情况难以预测的问题。例如，PEBG[12]利用习题-知识点关系图和习题难度构建预训练模型，获得习题表征。Bi-CLKT[13]基于习题和知识点关系图，结合图对比学习方法获得习题表征。DGEKT[15]通过同时捕获习题-知识点关联关系和交互转移关系获得习题表征，提高了模型预测性能。MFKT[16]基于学习者-习题异构图学习学习者和习题表征。此外，LPKT[17]引入行为特征学习知识掌握状态的变化。EKT[18]引入习题文本编码。

通过考虑不同的影响因素，上述模型在学习者行为预测上取得了一定的效果。但现有大多数知识追踪模型考虑不够全面，无法更加综合地衡量学习者知识状态的变化。本文模型从多视角构建表达能力更全面的习题表征，并且融合了学习者的遗忘规律进行行为预测。

2.2 图表示学习

图表示学习通过学习图中节点的低维嵌入来保留图的结构和语义信息。图表示学习在推荐系统、欺诈检测系统和社交网络分析等领域取得了显著成功。GCN[19]基于频谱的图卷积神经网络，利用图傅里叶变换分解图信号，在频谱成分上进行卷积。GAT[20]采用注意力机制来学习节点表征。以上方法都是基于同构图，而习题-知识点关系图是典型的异构图。HAN[21]将异构图转换为多个基于元路径的同构图来学习各类型节点表征，DeepWalk[22]和 Node2Vec[23]依赖于随机游走来生成节点的嵌入，但这些方法往往忽略了图的全局结构信息。DGI[24]是一种无监督图表示对比学习方法，通过最大化局部节点表示与全局图总结之间的互信息来学习得到具有全局感知能力的节点嵌入。

本文将习题-知识点异构图基于元路径方式转换为习题-习题关系图，然后结合无监督方法预训练习题表征，使得习题表征包含与知识点的关联的同时能感知全局关联关系。

3 问题定义

1)知识追踪：在线教育系统中有 $|L|$ 个学习者、$|Q|$ 个习题和 $|S|$ 个知识点。学习者在特定学科上的历史作答记录可以表示为一个答题序列 $X=\{(q_1,a_1),\cdots,(q_{t-1},a_{t-1})\}$，其中，$q_i\in Q$ 代表学习者在 i 时刻的习题，a_i 为答题结果(1 表示回答正确，0 表示回答错误)。知识追踪的目标是基于学习者的历史作答记录序列，预测其在下一时刻 t 对习题 q_t 的作答结果 a_t。具体来说，需要估计条件概率 $p(a_t=1|q_t,X)$，这一

中国知网 https://www.cnki.net

概率反映了学习者在下一时刻正确回答习题的可能性。

2）习题-知识点关系图：根据学习者的历史行为数据，可构建习题与知识点之间的关系图。该图可以表示为一个异构图 $G=\{Q,S,\boldsymbol{R}\}$，其中 $Q=\{q_i\}_{i=1}^{|Q|}$ 为所有习题的集合，$S=\{s_i\}_{i=1}^{|S|}$ 为所有知识点的集合，$\boldsymbol{R}=[r_{ij}]\in\{0,1\}^{|Q|\times|S|}$ 为习题和知识点之间的邻接矩阵，$r_{ij}=1$ 表示习题 q_i 与知识点 s_i 有关。

3）习题关系图：基于习题-知识点关系图，可以得到隐含的习题关系图。该图可以表示为同构图 $G^Q=\{Q,R^Q\}$，其中，$R^Q=[r_{ij}^Q]\in\{0,1\}^{|Q|\times|Q|}$ 表示习题 i 和习题 j 基于具有相同知识点而相关联。由此可见，在图 G^Q 里，相关联的习题是相似的习题。

4）知识点关系图：与习题关系图类似，知识点关系图可以表示为同构图 $G^S=\{S,R^S\}$，其中，$R^S=[r_{ij}^S]\in\{0,1\}^{|S|\times|S|}$ 表示知识点 i 和知识点 j 因连接到相同习题而相关联。类似地，在图 G^S 里，相关联的知识点是相似的。

5）习题难度：习题 q_i 的难度 d_i 定义为训练集中习题 q_i 被错误回答的比率。

4 方法描述

4.1 模型架构设计

MEFKT 模型利用预训练模型从多个视角学习具有高质量表达能力的习题表征，并结合学习者的学习遗忘规律构建行为预测模型。MEFKT 的模型框架如图 1 所示，主要由 4 个部分组成，分别是基于图结构的习题表征学习、基于多维度属性信息的习题表征学习、多视角习题表征对齐与融合，以及融合遗忘的行为预测。具体而言，基于图结构的习题表征学习部分基于习题关系图，利用无监督对比学习方法预训练包含图结构信息的习题表征；基于多维度属性信息的习题表征学习部分基于节点相似性、习题难度等信息，得到包含多维度属性的预训练习题表征；多视角习题表征对齐与融合部分利用线性映射机制，将结构与属性信息统一至同一表征空间，从而得到最终的习题表征；融合遗忘的预测部分利用记忆力衰减的注意力机制构建行为预测模型，实现对学习者知识状态的动态更新并预测下一个习题的答题情况。

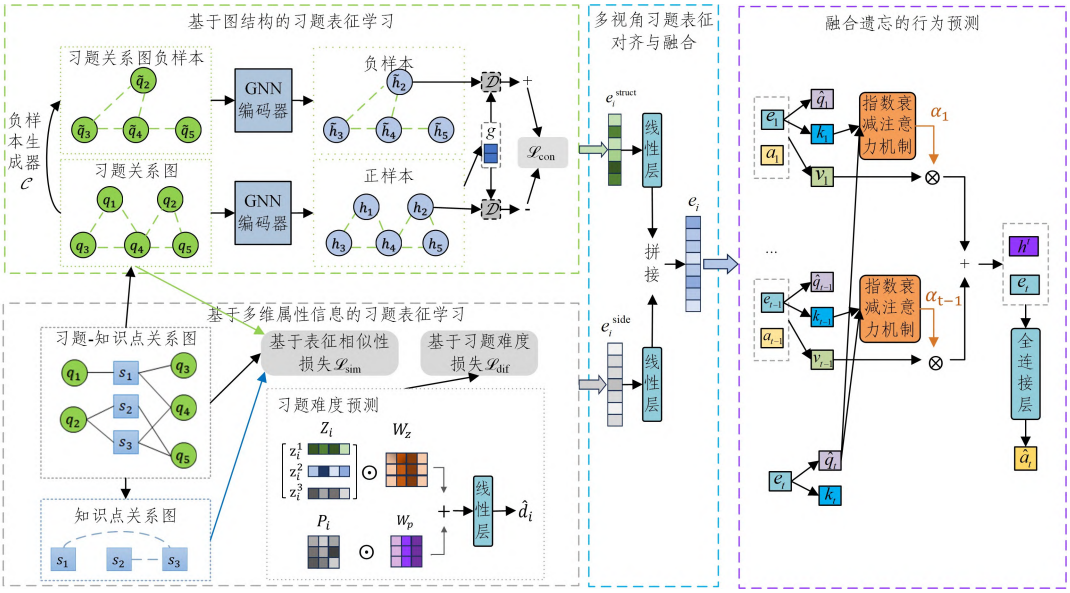

图 1 MEFKT 模型架构

Fig. 1 Framework of MEFKT

4.2 基于图结构的习题表征学习

为充分挖掘习题之间的隐含结构特征信息，MEFKT 基于习题关系图 G^Q，利用无监督图对比学习方法来学习习题嵌入表示，为后续任务提供更丰富的语义和结构特征。

利用负样本生成器 C 对图 G^Q 进行随机扰动，得到负样本习题关系图 $\widetilde{G}^Q$，即 $C(\boldsymbol{Q},\boldsymbol{R}^q)=(\widetilde{\boldsymbol{Q}},\widetilde{\boldsymbol{R}}^q)$。具体扰动方式是：通过对 $\boldsymbol{Q}$ 进行行级别的洗牌操作，即邻接矩阵保持不变，$\widetilde{\boldsymbol{R}}^q=\boldsymbol{R}^q$，随机打乱习题表征矩阵 $\boldsymbol{Q}$ 内行与行之间的顺序得到 $\widetilde{\boldsymbol{Q}}$，从而破坏节点与原有邻居的对应关系。这种方式能在不改变全局统计特征（如节点度分布）的情况下，生成结构破坏较大的负样本，相比随机删除边或特征扰动等方式，该方法能产生更强的特征[24]。

对两个图 G^Q 和 $\widetilde{G}^Q$，分别用 GNN 编码器得到所有节点表示 H 和 $\widetilde{H}$。本文采用图卷积网络 GCN 作为 GNN 编码器，GCN 通过多层卷积操作来编码高阶邻居信息。G^Q 中 l 层的节点表示为：

$$H^{(l)}=\mathrm{ReLU}(\widetilde{\boldsymbol{D}}^{-\frac{1}{2}}\widetilde{\boldsymbol{R}}^Q\widetilde{\boldsymbol{D}}^{-\frac{1}{2}}\boldsymbol{H}^{(l-1)}\boldsymbol{W}^{(l-1)}) \tag{1}$$

其中，$\widetilde{\boldsymbol{R}}^Q=\boldsymbol{R}\boldsymbol{W}^Q+\mathbf{I}$ 为加自环的邻接矩阵，$\widetilde{\boldsymbol{D}}$ 为 $\widetilde{\boldsymbol{R}}^Q$ 的度矩阵，$\boldsymbol{H}^{(l-1)}$ 为第 $l-1$ 层的输入特征，$\boldsymbol{H}^{(0)}=\boldsymbol{Q}$，$\boldsymbol{W}^{(l-1)}$ 是第 $l-1$ 层的权重矩阵。此处，习题 $q_i\in\mathbb{R}^{|S|}$ 的初始特征是由与其关联的知识点的 multi-hot 向量来表示的，所有节点特征组成习题特征矩阵 $\boldsymbol{Q}\in\mathbb{R}^{|Q|\times|S|}$，$q_i$ 是矩阵 $\boldsymbol{Q}$ 的第 i 行。图 G^Q 经过 L 层的 GCN 的最终输出 $\boldsymbol{H}=\boldsymbol{H}^{(L)}\in\mathbb{R}^{|Q|\times d_s}$，$h_i\in\mathbb{R}^{d_s}$ 是 $\boldsymbol{H}$ 中的第 i 行，$\widetilde{G}^Q$ 经过类似操作得到最终输出 $\widetilde{\boldsymbol{H}}=\widetilde{\boldsymbol{H}}^{(L)}\in\mathbb{R}^{|Q|\times d_s}$。

通过 GNN 编码器得到的各节点表征，经过池化操作，得到整体图摘要的嵌入表示 $g=\sigma(\mathrm{mean}(H))$，$\sigma$ 为 sigmoid 激活函数，$g\in\mathbb{R}^{d_s}$。最后，使用最大化互信息机制[24]，结合一个鉴别正负样本的鉴别器 D，利用无监督的对比学习方法获得

中国知网 https://www.cnki.net

最终的基于图结构的习题嵌入。损失函数如式(2)所示：

$$\mathcal{L}_{\mathrm{con}}=\frac{1}{2|Q|}\left[\sum_{i=1}^{|Q|}\mathbb{E}_{\mathrm{pos}}[\log D(h_i,g)]+\sum_{j=1}^{|Q|}\mathbb{E}_{\mathrm{neg}}[\log(1-D(\tilde{h}_j,g))]\right] \tag{2}$$

其中，鉴别器 D 用来区分正样本对和负样本对。若节点 q_i 来自原始图 G^{Q}，则 (h_i,g) 是正样本对；若 $\tilde{q}_i$ 来自原始图 $\tilde{G}^{\mathrm{Q}}$，则 $(\tilde{h}_i,g)$ 是负样本对。$D(h_i,g)=\sigma(h_i^{\mathrm{T}}W_D g)$ 表示输入属于正样本对的概率，$W_D\in\mathbb{R}^{d_s}$ 是可学习参数。训练结束后，对于习题 q_i，将得到具有图结构信息的习题嵌入表示 $e_i^{\mathrm{struct}}=h_i$。

4.3 基于多维度属性信息的习题表征学习

为了能够获得具有多维度属性信息的习题表征，随机初始化各知识点和习题节点的初始特征，利用习题多维度属性信息构建习题难度预测模型和多个损失函数来迭代更新各节点特征。

随机初始化知识点和习题特征矩阵 $\boldsymbol{S}\in\mathbb{R}^{|S|\times d_f}$，$\boldsymbol{Q}\in\mathbb{R}^{|Q|\times f}$，其中 d_f 是特征维度。同时，利用习题响应时间和习题类型等与习题难度相关的属性信息构建习题难度特征。具体而言，习题 q_i 的属性特征 $f_i=[f_i^1;\cdots;f_i^m]$，m 表示难度特征维度，具体维度数量由具体数据集而定。例如，当第 j 个属性是习题类型时，f_i^j 表示习题 q_i 的习题类型的 one-hot 向量；当第 j 个属性是响应时间时，f_i^j 表示平均响应时间标量。

本文结合习题特征、知识点特征以及习题难度特征来构建习题难度预测模型，并利用平方误差总和作为损失训练模型。具体来说，将 f_i 投影到与 $\boldsymbol{S}$ 和 $\boldsymbol{Q}$ 相同的维度空间中，从而得到习题的难度特征向量 $z_i^1\in\mathbb{R}^{d_f}$。此外，与习题 q_i 关联的所有知识点集合为 $C_i=\{s_j\mid r_{ij}=1\}$，可以通过聚合相关知识点来得到习题 q_i 的知识点表示形式 $z_i^2=\mathrm{mean}(C_i)$。

接着，将习题 q_i 的难度特征 z_i^1、习题知识点表示 z_i^2 以及原始特征 $z_i^3=q_i$ 进行堆叠，得到习题综合表示 $\boldsymbol{Z}_i=(z_i^1,z_i^3,z_i^3)\in\mathbb{R}^{3\times d_f}$。此外，还可以得到两两特征相关性信息 $\boldsymbol{P}_i=[p_{jj'}]\in\mathbb{R}^{3\times 3}$，其中 $p_{jj'}=(z_i^j)^{\mathrm{T}}(z_i^{j'})$，$j,j'\in\{1,2,3\}$。

根据式(3)，利用 $\boldsymbol{Z}_i$ 和 $\boldsymbol{P}_i$ 得到融合多维度属性信息的习题嵌入表示 $e_i^{\mathrm{side}}\in\mathbb{R}^{d_f}$：

$$e_i^{\mathrm{side}}=\mathrm{ReLU}(ez_i+ep_i+b) \tag{3}$$

其中，$ez_i=(ez_i^{(1)},\cdots,ez_i^{(d')})$，$ep_i=(ep_i^{(1)},\cdots,ep_i^{(d')})$，$ez_i^{(k)}=\boldsymbol{Z}_i\odot\boldsymbol{W}_z^{(k)}$，$ep_i^{(k)}=\boldsymbol{P}_i\odot\boldsymbol{W}_p^{(k)}$，$k\in[1,\cdots,d_f]$，$\boldsymbol{W}_z^{(k)}\in\mathbb{R}^{3\times d_f}$，$\boldsymbol{W}_z^{(k)}\in\mathbb{R}^{3\times 3}$ 和 $b\in\mathbb{R}^{d_f}$ 是学习参数，$\odot$ 操作将两矩阵按元素相乘再相加，从而得到一个标量。

最后，将 e_i^{side} 输入一个线性层来预测习题 q_i 的难度 $\hat{d}_i$。使用平方误差总和作为损失函数：

$$\mathcal{L}_{\mathrm{dif}}=\sum_{i=1}^{|Q|}(d_i-\hat{d}_i)^2 \tag{4}$$

此外，可以基于不同关联关系图构建相似性损失函数 $\mathcal{L}_{\mathrm{sim}}$ 来联合更新习题嵌入表示。以习题-知识点关系图为例，使用内积来评估所有习题和知识点节点在表征空间的关联度 $\hat{r}_{ij}=\sigma(q_i^{\mathrm{T}}s_j)$。基于习题-知识点关系图的相似性损失函数是基于真实关联关系 r_{ij} 和预测关联性 $\hat{r}_{ij}$ 的交叉熵损失函数：

$$\mathcal{L}_{\mathrm{sim}}^{\mathrm{QS}}=\sum_{i=1}^{|Q|}\sum_{j=1}^{|S|}-r_{ij}\log\hat{r}_{ij}-(1-r_{ij})\log(1-\hat{r}_{ij}) \tag{5}$$

同时，还可以构建基于习题关系图和知识点关系图的相似性损失函数 $\mathcal{L}_{\mathrm{sim}}^{\mathrm{QQ}}$ 和 $\mathcal{L}_{\mathrm{sim}}^{\mathrm{SS}}$。基于关系图的相似性损失 $\mathcal{L}_{\mathrm{sim}}=\mathcal{L}_{\mathrm{sim}}^{\mathrm{QS}}+\mathcal{L}_{\mathrm{sim}}^{\mathrm{QQ}}+\mathcal{L}_{\mathrm{sim}}^{\mathrm{SS}}$。由此，最终损失函数为：

$$\mathcal{L}_{\mathrm{sid}}=\mathcal{L}_{\mathrm{dif}}+\lambda\mathcal{L}_{\mathrm{sim}} \tag{6}$$

其中，$\lambda\in[0,1]$ 是超参数，用于平衡两种损失权重。训练结束后，对于习题 q_i，将得到融合多维度属性信息的习题嵌入表示 e_i^{side}。

4.4 多视角习题表征对齐与融合

习题 q_i 的结构嵌入 $e_i^{\mathrm{struct}}\in\mathbb{R}^{d_s}$ 与多属性习题嵌入 $e_i^{\mathrm{side}}\in\mathbb{R}^{d_f}$ 来自不同的视角和嵌入空间，直接拼接可能引起信息冗余或表征冲突。为实现统一表示空间下的有效信息融合，本文设计了线性变换对齐机制。具体而言，将两类习题嵌入线性映射到同一表征空间，计算式如下：

$$\begin{cases}\tilde{e}_i^{\mathrm{struct}}=w_s^{\mathrm{T}}\cdot e_i^{\mathrm{struct}}+b_s\\ \tilde{e}_i^{\mathrm{side}}=w_f^{\mathrm{T}}\cdot e_i^{\mathrm{side}}+b_f\end{cases} \tag{7}$$

其中，$w_s\in\mathbb{R}^{d_s\times d}$，$w_f\in\mathbb{R}^{d_f\times d}$；$b_s,b_f\in\mathbb{R}^d$ 都是模型参数；$\tilde{e}_i^{\mathrm{struct}}$，$\tilde{e}_i^{\mathrm{side}}\in\mathbb{R}^d$。

再将它们拼接，获得习题的最终嵌入向量 $e_i\in\mathbb{R}^{2d}$：

$$e_i=[\tilde{e}_i^{\mathrm{struct}};\tilde{e}_i^{\mathrm{side}}] \tag{8}$$

4.5 融合遗忘的行为预测

为充分考虑知识遗忘规律对学习者知识掌握的影响，MEFKT 利用融合指数衰减的注意力机制进行行为预测建模，实现对学习者知识状态的动态更新及对下一个答题结果的预测。

上一节获得的融合习题结构和多属性信息的各习题嵌入 e_i 经过线性变换得到 $\hat{q}_i$ 和 k_i，将 e_i 与交互结果 r_i 拼接并进行线性变换得到 v_i，并且 $\hat{q}_i,k_i,v_i\in\mathbb{R}^{d_k}$。基于学习者的历史答题序列 X，利用指数衰减的注意力机制得到时刻 i 的相关知识掌握情况的权重 $\alpha_{t,i}\in[0,1]$：

$$\alpha_{t,i}=\mathrm{softmax}\left(\frac{decay(t,i)\cdot\hat{q}_i^{\mathrm{T}}k_i}{\sqrt{d_k}}\right) \tag{9}$$

其中，$i\in[1,\cdots,t-1]$，$decay(t,i)$ 是一个指数衰减程度函数：

$$decay(t,i)=\exp(-\theta\cdot d(t,i)) \tag{10}$$

其中，$\theta>0$ 是一个可学习的衰减率参数；$d(t,i)$ 是用来计算时刻 t 和 i 之间的可感知上下文的时序距离函数，它不仅考虑了 t 和 i 之间的时间距离，还考虑了 t 和 i 之间的习题与当前习题的相关程度。

$$d(t,i)=|t-i|\sum_{j=i+1}^{t}\beta_{t,j} \tag{11}$$

$$\beta_{t,j}=\mathrm{softmax}(\hat{q}_j^{\mathrm{T}}k_j/\sqrt{d_k}),\forall j\leqslant t \tag{12}$$

对历史各时刻权重 $\alpha_{t,i}$ 和答题情况 v_i 加权求和，得到当前 t 时刻学习者的知识掌握情况 $\sum_{i=1}^{t-1}\alpha_{t,i}v_i$。本文应用多头注意力机制来建模知识掌握情况，注意力头数量为 K，每个头具有独立的衰减率 θ，拼接每个头得到 t 时刻学习者的知识掌握情况表征向量 $h^t\in\mathbb{R}^{d_k\cdot K}$。将 h^t 和当前习题嵌入 e_i 共同输入全连接层，并利用 sigmoid 函数来预测 t 时刻习题 q_i 的答对概率：

$$\hat{a}_i^t=\mathrm{sigmoid}(w^{\mathrm{T}}\cdot[h^t;e_i]+b) \tag{13}$$

其中，$w\in\mathbb{R}^{d_k\cdot K+2d}$ 和 $b\in\mathbb{R}$ 是可学习参数，$\hat{a}_i^t\in[0,1]$。

中国知网 https://www.cnki.net

最后，使用训练集中所有学习者历史记录的二分类交叉熵损失函数训练模型。

$$\mathcal{L}_{\text{pre}}=\sum_{i=1}^{|L|}\sum_{t}-a_t^i\log\hat{a}_t^i-(1-a_t^i)\log(1-\hat{a}_t^i) \tag{14}$$

5 实验及结果分析

5.1 数据集

本文在 ASSISTment2009 和 EdNet 两个数据集上进行实验。它们是知识追踪领域公开的基准数据集，包含丰富的学习者答题记录、习题与知识点的关联关系等信息，适合验证多视角的习题表征与遗忘机制对预测性能的提升作用。表 1 列出了这两个数据集的基本信息。

表 1 数据集信息统计

Table 1 Statistics of datasets

基本信息	ASSISTment 2009	EdNet
记录数	190 320	222 141
学习者数	3 841	5 000
习题数	15 911	13 169
知识点数	123	188
序列平均长度	49.55	44.43
平均答题次数	11.96	16.87
习题类型数	5	1
平均答题时长/ms	57 392	49 578

ASSISTment2009 来自 ASSISTments 在线教育辅导平台，数据预处理删除了没有知识点的答题记录以及记录数少于 3 条的学习者 ID。经过预处理后，数据集包含 123 项知识点、3 841 名学习者回答的 15 911 道习题，总计 190 320 条记录。EdNet 是在 Santa 教育应用上收集的学习者行为数据，本实验中使用由学习者解题日志组成的 EdNet-KT1 数据集，随机抽样 5 000 名学习者的 222 141 条记录，其中包含 13 169 道习题和 188 项知识点。

5.2 基线实验

为了验证 MEFKT 模型的性能，将其与以下基线方法进行比较。

1）DKT[8]：第一个将深度学习方法应用于知识追踪的模型，使用 LSTM 预测未来的答题表现。

2）AKT[10]：结合指数衰减的自注意力机制与 IRT 模型来预测学习者的答题表现。

3）PEBG＋DKT[12]：利用预训练模型学习习题嵌入，并将其结合到现有模型 DKT，以实现预测。

4）LBKT[11]：基于学习过程中的遗忘因素更新学习者的知识状态变化，进而训练知识追踪模型。

5）DGEKT[15]：同时捕获习题-知识点关联关系和交互转移关系，提高模型预测性能。

这些基线方法涵盖经典 RNN、注意力机制、预训练嵌入、遗忘建模及图结构增强模型，能全面验证本文方法的性能。

5.3 实现细节与评价指标

本文在 PyTorch 框架下实现 MEFKT 模型，模型超参数采用网格搜索在验证集上调优而得，以兼顾模型性能与泛化能力。GNN 编码器使用 2 层 GCN 实现，中间隐藏层维度为 512。模型各类嵌入向量维度设置为$d_s=d_f=d=d_k=128$，多头注意力机制为 $K=8$，式(6)中 $\lambda=0.5$。使用 Adam 优化器训练模型，学习率为 0.001，在每个 epoch 进行了学习率衰减，最大 epoch 为 100。数据集 ASSISTment2009 的习题难度特征包括平均响应时间和习题类型（习题难度特征维度 $m=2$），数据集 EdNet 的习题难度特征只包含平均响应时间（$m=1$）。本文按照学习者的数量，将数据集划分为训练集/验证集和测试集，划分比例为 8∶2。所有的实验都在 NVIDIA Tesla V100 PCIE 40 GB GPU 的 Linux 服务器上进行。

本文采用 ROC 曲线下的面积（AUC）和准确率（ACC）作为评估指标。对于不同数据集，基于不同初始参数独立训练和测试模型 5 次，并以所有测试结果的均值作为最终实验结果。

5.4 实验结果与分析

表 2 列出了所有方法在两个数据集上的性能，最好的指标值加粗表示。实验结果表明，MEFKT 模型在所有数据集上的性能均优于其他基线方法。在数据集 ASSISTment2009 上，MEFKT 对比基线方法的 *AUC* 平均提高了 6.67%，*ACC* 平均提高了 4.26%；在数据集 EdNet 上，MEFKT 的 *AUC* 平均提高了 12.16%，*ACC* 平均提高了 6.12%。这表明，通过习题结构和多维度属性信息增强的习题表征能够有效提高模型对学习者知识状态的评估。具体而言，与传统的抽象建模方法（如 DKT）不同，本文方法利用图结构和属性信息得到增强的习题嵌入表示，能有效帮助模型从多个角度充分理解习题本身，再通过融合学习者的学习规律构建预测模型来提升性能。此外，MEFKT 也明显优于其他先进的基线模型，这是因为 AKT 和 LBKT 模型虽然融合了遗忘机制，但缺少对习题更准确的理解；而 PEBG 未从图结构角度进一步增强习题嵌入表达能力；DGEKT 虽然从图结构角度提升了交互嵌入表达能力，但其未考虑习题难度以及学习规律等方面。MEFKT 通过习题图结构和多维度属性特征来提升习题嵌入表达能力，同时利用指数衰减的注意力机制模拟学习者学习遗忘规律，从而进一步提升了模型性能。

表 2 对比实验结果

Table 2 Comparison experiment results

模型	ASSISTment2009		EdNet	
	AUC	*ACC*	*AUC*	*ACC*
DKT	0.712 6	0.702 1	0.717 3	0.701 5
AKT	0.759 5	0.721 4	0.729 5	0.718 9
PEBG＋DKT	0.802 8	0.748 7	0.757 9	0.730 2
LBKT	0.775 2	0.732 6	0.736 4	0.725 1
DGEKT	0.768 9	0.720 5	0.704 8	0.657 5
MEFKT	**0.830 5**	**0.767 7**	**0.850 8**	**0.767 8**

5.5 消融实验

为研究 MEFKT 模型中不同模块的作用，在 ASSISTment2009 和 EdNet 两个数据集上进行消融实验，设计 4 种变体模型，分别从图结构习题表征、多属性习题表征、对齐机制以及指数衰减机制 4 个方面进行验证。

实验结果如表 3 所列，当移除任何一个模块时，模型的性能均有所下降，这验证了每个模块在模型中的有效性。MEFKT-struct 表示去除基于图结构的习题嵌入，仅使用基于多属性信息的习题嵌入作为后续输入。MEFKT-struct 在

中国知网 https://www.cnki.net

两个数据集的性能相比 MEFKT 都有所下降，这表明习题的结构信息在提升模型预测性能上具有明显贡献。MEFKT-side 为保留基于图结构的习题嵌入，仅去除多维度属性习题嵌入部分，实验结果显示其模型性能下降更为显著，这表明了融合习题难度及关系图相似性的多维度属性特征的习题嵌入较大程度地提升了习题嵌入的表达能力。MEFKT-align 是去除了多源嵌入对齐层，直接将基于图结构的习题嵌入和基于多属性信息的习题嵌入拼接后输入到预测模块。结果显示，MEFKT-align 的性能下降最大，说明对齐层在融合异构特征表示时具有关键作用，这是因为对齐机制能够有效缓解不同表征空间的不一致问题，使模型更好地融合两类嵌入，从而提升模型预测性能。MEKT-decay 去除了指数衰减机制，即去掉式(9)中的指数衰减函数 $decay(\cdot)$。结果显示，MEKT-decay 的性能在两个数据集上都有明显下降，这说明本文方法中的指数衰减机制能很好地对学习者遗忘规律进行建模并提高预测性能。

表 3 消融实验结果

Table 3 Ablation experiment results

模型	ASSISTment2009		EdNet	
	AUC	*ACC*	*AUC*	*ACC*
MEFKT-struct	0.8106	0.7513	0.8322	0.7545
MEFKT-side	0.7856	0.7337	0.6977	0.6719
MEFKT-align	0.7201	0.6990	0.6689	0.6450
MEKT-decay	0.7912	0.7405	0.8021	0.7326
MEFKT	**0.8305**	**0.7677**	**0.8508**	**0.7678**

5.6 模型关键参数分析

5.6.1 GNN 编码器的层数

基于图结构的习题表征学习中使用 GCN 作为 GNN 编码器，本节固定模型的其他参数，改变 GCN 层数来运行 MEFKT，展示 GCN 层数对性能的影响。结果如图 2 所示。

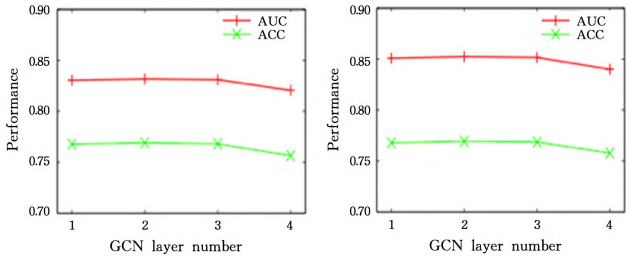

(a) ASSISTment2009 (b) EdNet

图 2 GNN 编码器层数对性能的影响

Fig. 2 Performance of different GCN layer numbers

从图 2 可以发现，MEFKT 的性能在两个数据集中都在 GCN 层数为 2 时达到峰值，然后随着层数的增加，性能有所下降。这是由于 GCN 前期随着层数的增加能有效整合更远的邻居信息，从而增强节点表征的表达能力；但随着层数继续增加，会出现过平滑问题，使得节点表征趋于相似，导致性能下降。本文基于模型在验证集的表现，设置 GCN 层数为 2。

5.6.2 损失函数权重参数 λ

基于多维度属性的习题表征学习中，使用参数 λ 调节表征相似性和习题难度两类损失函数权重。本节固定其他参数，改变 λ 值来运行 MEFKT，展示 λ 对模型性能的影响。实验结果如图 3 所示。

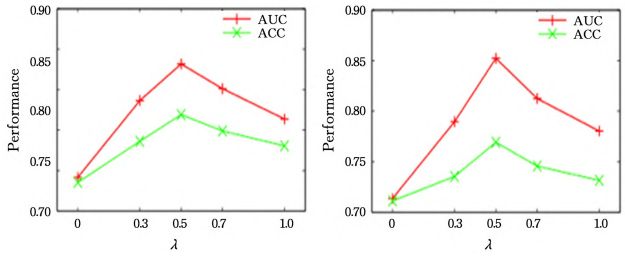

(a) ASSISTment2009 (b) EdNet

图 3 权重参数 λ 值对性能的影响

Fig. 3 Performance of different λ values

从图 3 可以发现，在两个数据集上，MEFKT 的性能在 $\lambda=0.5$ 处达到峰值，并且在 $\lambda=0$ 和 $\lambda=1$ 处达到性能最低和次低，说明相似性损失函数和习题难度损失函数对习题表征的表达能力的影响都很大，且同时使用效果会更佳。本文基于模型在验证集的表现，设置权重参数 $\lambda=0.5$。

5.6.3 习题嵌入维度

在多视角的习题表征对齐与融合过程中，利用线性映射将两个视角的习题嵌入统一至同一表征空间。本节固定模型的其他参数，通过调整线性层来改变最终习题嵌入维度 d，展示习题嵌入维度对模型性能的影响。实验结果如图 4 所示。

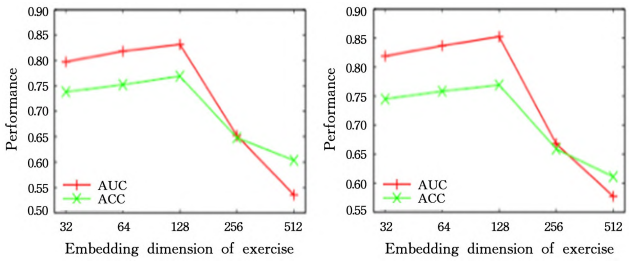

(a) ASSISTment2009 (b) EdNet

图 4 习题嵌入表征维度对性能的影响

Fig. 4 Performance of different embedding dimensions of exercise

从图 4 可以发现，在两个数据集上，MEFKT 的性能随着嵌入维度的增大而提升，并在维度为 128 时达到峰值，随后开始下降。这是因为当嵌入维度过小时，模型需要通过线性层对来自两个视角的表征进行降维操作，从而造成习题表征信息的损失。此外，当嵌入维度过大时，还可能引入冗余或噪声特征，增加模型的过拟合风险，导致性能下降。本文基于模型在验证集的表现，将习题嵌入维度设定为 128。

5.7 实验结果可视化分析

5.7.1 知识状态可视化

知识追踪的主要目的是通过建模学习者的历史答题行为来预测其未来的答题情况，因此本文对模型捕捉学习者知识状态变化的过程进行可视化展示。从 ASSISTment2009 数据集中截取某一学习者的答题序列，追踪其知识状态的变化情况，从而说明引入习题结构和多维度属性信息以及融合遗忘因素对学习者知识状态变化的影响效果。

图 5 为知识状态变化热力图，其中横坐标展示了学习者答题的信息，纵坐标表示具体的习题、知识点、响应、回答时间、间隔时间和习题难度，每个单元格反映了学习者对特定知

中国知网 https://www.cnki.net

识点的掌握程度，颜色越深表示学习者对该知识点的掌握程度越高。首先，学习者答对习题时，对应知识点掌握程度提升；答错习题时，对应知识点掌握程度将会下降。其次，当学习者答对某个知识点的相关习题时，其对与该知识点具有强关联性的其他知识点的掌握程度也会提升。例如，学习者答对了知识点 1 的对应习题 q7，学习者对知识点 1 和与知识点 1 具有较高相关性的知识点 13 的掌握程度都得到了提升。这说明 MEFKT 模型能够模拟出知识点关联性对知识状态的影响。再次，知识掌握状态受到多种因素影响，包括习题难度、回答时间等习题属性信息。例如，在关联知识点 1 的习题中，对于难度较高的 q1，q2 和 q4，q5，学习者都答错了，而难度较低的 q6，q7 都答对了。同时，对应同一知识点的习题中，回答时间较长的习题大部分都答对了，这可能是因为学习者通过学习和思考提高了对知识点的掌握程度。以上说明知识状态受到习题多维度属性信息的影响。MEFKT 通过引入多维度属性信息，提高了学习者对知识掌握的准确性。最后，学习遗忘规律也会影响学习者对知识掌握的情况。例如，学习者在正确回答习题 q9 之后却答错了习题 q10，而 q10 的难度低于 q9，表明学习者对于相应知识点 13 的掌握状态下降了。这可能是由于这两道题的答题间隔时间较长，受到遗忘规律影响，学习者的知识掌握状态下降，回答错误。这说明 MEFKT 模型能模拟出遗忘因素对学习者知识状态变化的影响。

图 5　知识状态变化热力图

Fig. 5　Heatmap of knowledge state change

5.7.2　习题聚类可视化

为进一步验证所提模型中融合嵌入的有效性，采用 T-SNE 方法对 MEFKT 模型学习到的习题表示进行降维可视化分析。在本实验中，选取 ASSISTment2009 数据集中出现频率最高的 10 个知识点，将对应 MEFKT 模型得到的最终习题嵌入进行二维投影，并以不同颜色标识不同的知识点编号，绘制聚类分布图。习题聚类可视化结果如图 6 所示。

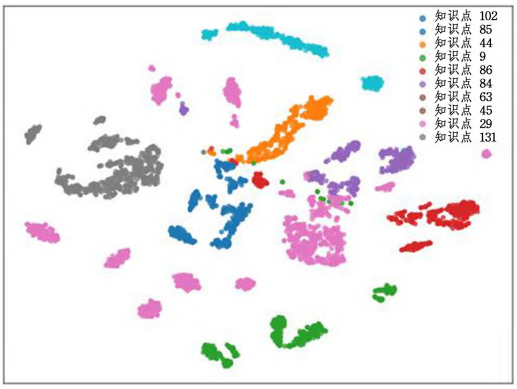

图 6　ASSISTment2009 数据集的习题聚类可视化

（电子版为彩图）

Fig. 6　Visualization of exercise clustering on ASSISTment2009 dataset

从图 6 可以观察到，学习到的习题嵌入在大多数知识点维度上表现出明显的聚类趋势，说明模型能够有效地将具备相同知识点的习题聚集在相近的表示空间内。部分知识点（如知识点 86 和知识点 131 等）聚类结构清晰且紧凑，同时也存在少数知识点（如知识点 29）在低维空间中呈现较为分散的分布，这可能是知识点关联的习题覆盖面较广，结构和属性特征差异较大所致。总体来说，MEFKT 模型通过融合习题图结构和多维度属性信息，提升了习题表征的表达能力，使得相似习题能够在嵌入空间中相互靠近，为后续的知识状态建模和预测任务提供了更有效的输入表示，进一步验证了模型的有效性。

结束语　本文针对当前知识追踪模型在习题表征方面存在结构信息与多维度属性信息融合不足以及未充分考虑学习者学习知识遗忘规律对知识掌握预测存在影响的问题，提出了一种融合多视角的习题表征与遗忘机制的深度知识追踪模型 MEFKT，分别从习题-知识点关系图结构和多维度属性信息视角来增强习题表征的表达能力，并以此为基础设计融合遗忘规律的行为预测模型，建模学习者的知识掌握情况并预测其对下一题的回答。本文在两个公开数据集上进行了对比实验、消融实验和可视化解释实验，结果验证了 MEFKT 方法的有效性和先进性。此外，本研究当前聚焦于客观题型（如选择题、判断题等）的答题正误预测，其输出结果为二分类（正确/错误）。对于主观题型（如简答题、分析题等）的得分预测，由于答案不唯一且需连续评分，现有模型暂未涵盖。后续研究将针对主观题特性，设计适配的知识追踪模型。

参 考 文 献

[1] ABDELRAHMAN G，WANG Q，NUNES B. Knowledge tracing：A survey[J]. ACM Computing Surveys，2023，55(11)：1-37.

[2] WU Z Y，TANG Y，LIU H. A Suvey of Personalized Learning Recommendation Research[J]. Computer Science and Exploration，2022，16(1)：21-40.

[3] LI JW，WU J H，JI Y L. Personalized Learning Path Recommendation for Adaptive Learning[J]. Modern Educational Technology，2023，33(1)：108-117.

中国知网 https://www.cnki.net

[4] CORBETT A T, ANDERSON J R. Knowledge tracing: Modeling the acquisition of procedural knowledge[J]. User Modeling and User-adapted Interaction, 1995(4): 253-278.

[5] SONG X, LI J, LEI Q, et al. Item response theory [J]. Annual Review of Statistics and Its Application, 2016, 3(1): 297-321.

[6] WANG Y, ZHU M X, YANG S H, et al. Review and Performance Comparison of Deep Knowledge Tracing Models[J]. Ruan Jian Xue Bao/Journal of Software, 2023, 34(3): 1365-1395.

[7] ZHANG N, JIANG B. A Survey on Research Progress of Learner Knowledge Tracing [J]. Computer Science, 2021, 48(4): 213-222.

[8] PIECHC, BASSEN J, HUANG J, et al. Deep knowledge tracing [C] // Advances in Neural Information Processing Systems. 2015.

[9] PANDEYS, KARYPIS G. A self-attentive model for knowledge tracing[J]. arXiv: 1907. 06837, 2019.

[10] GHOSH A, HE-FFERNAN N, LAN A S. Context-aware attentive knowledge tracing[C] // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 2330-2339.

[11] XU B, HUANG Z, LIU J, et al. Learning behavior-oriented knowledge tracing [C] // Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 2789-2800.

[12] LIUY, YANG Y, CHEN X, et al. Improving knowledge tracing via pre-training questi-on embeddings[J]. arXiv: 2012. 05031, 2020.

[13] SONG X, LI J, LEI Q, et al. Bi-CLKT: Bi-graph contrastive learning based knowledge tracing[J]. Knowledge-Based Systems, 2022, 241: 108274.

[14] ZHANG J, SHI X, KING I, et al. Dynamic key-value memory networks for knowledge tracing[C] // Proceedings of the 26th International Conference on World Wide Web. 2017: 765-774.

[15] CUI C, YAO Y, ZHANG C, et al. DGEKT: A dual graph ensemble learning method for knowledge tracing[J]. ACM Transactions on Information Systems, 2024, 42(3): 1-24.

[16] YAN Q Y, SUN H, SI Y Q, et al. Multimodality and Forgetting Mechanisms Model for Knowledge Tracing[J]. Computer Science, 2024, 51(7): 133-139.

[17] SHEN S, LIU Q, CHEN E, et al. Learning process-consistent knowledge tracing [C] // Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 1452-1460.

[18] LIU Q, HUANG Z, YIN Y, et al. Ekt: Exercise-aware knowledge tracing for student performance prediction [J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 33(1): 100-115.

[19] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[J]. arXiv: 1609. 02907, 2016.

[20] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph attention networks[J]. arXiv: 1710. 10903, 2017.

[21] WANG X, JI H, SHI C, et al. Heterogeneous graph attention network[C] // The World Wide Web Conference. 2019: 2022-2032.

[22] PEROZZI B, AL-RFOU R, SKIENA S. Deepwalk: Online learning of social representations [C] // Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2014: 701-710.

[23] GROVER A, LESKOVEC J. Node2Vec: Scalable feature learning for networks[C] // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 855-864.

[24] VELIČKOVIĆ P, FEDUS W, HAMILTON W L, et al. Deep graph infomax[J]. arXiv: 1809. 10341, 2018.

YU Chengcheng, born in 1986, Ph. D, master's supervisor, is a member of executive committee on information system of CCF (No. 81482M). Her main research interests include education data analysis and graph data mining.

CHEN Fangshu, born in 1989, Ph. D, master's supervisor. Her main research interests include data mining, graph databases, and spatial and temporal data analysis.

（责任编辑：喻藜）

中国知网 https://www.cnki.net